Bhap — Product Requirements Document (PRD)

Product name: Bhap — Private Offline Knowledge Intelligence
Version: 1.2 (Codex-style Interactive CLI Edition)
Status: Product concept / ready for technical planning (CLI-first revision)
Type: Offline-first, open-source, terminal-native AI knowledge assistant (desktop GUI optional)
Primary platform: Linux (CachyOS/Arch, Ubuntu), followed by Windows and macOS
Product tagline: Your knowledge. Your machine. Your intelligence.
Distribution: Git repository (`git clone`), Python package (`pipx` / uv `tool`), optional binaries **Primary interface:** Interactive CLI launched by bare bhap (Codex-style); scriptable subcommands secondary

---

1. Executive Summary

Bhap adalah terminal-first AI assistant yang dapat membaca, mengindeks, mengorganisasi, mencari, dan menggunakan pengetahuan dari file milik pengguna tanpa memerlukan koneksi internet saat beroperasi. Pengguna menambahkan PDF, DOCX, PPTX, Markdown, atau TXT ke suatu *knowledge workspace*. Aplikasi mengekstraksi konten dan metadata, memecah konten sesuai struktur, membuat embedding lokal, lalu menyimpannya dalam indeks pencarian lokal. Ketika pengguna mengajukan pertanyaan, Bhap mencari bagian dokumen yang paling relevan dan mengirimkannya ke large language model (LLM) lokal untuk menghasilkan jawaban beserta sitasi menuju halaman, slide, atau bagian dokumen.

Keputusan kunci: Bhap bukan proyek *train a new foundation model from user PDFs*. Versi awal menggunakan **local RAG** dengan memori percakapan dan profil belajar tersimpan secara terpisah. Semua model, tokenizer, embedding engine, dan dependensi penting harus sudah tersedia di disk sebelum perangkat berpindah ke mode offline.

Value proposition: “Clone sekali, siapkan model lokal, tambahkan materi, lalu gunakan kapan saja dari terminal—bahkan tanpa Wi-Fi.”

Distribution contract: Source code dapat di-`git clone` oleh orang lain. `git clone` hanya mengambil code, bukan otomatis menyiapkan Python, model LLM, embedding, OCR, atau dependensi OS. Sediakan `bhap doctor`, `bhap setup`, dokumentasi lintas platform, lockfiles, serta mode *air-gapped installation* melalui paket artefak yang disiapkan lebih dahulu. Setelah setup selesai, proses ingestion dan

chat harus offline. Jangan mewajibkan pengguna mengunggah dokumen ke cloud.

2. Problem Statement

- Chatbot berbasis cloud tidak bisa diandalkan saat koneksi internet hilang.
- File kuliah, laporan, slide, dan catatan tercecer dan sulit dicari secara semantik.
- Pencarian teks biasa tidak menjelaskan hubungan antarmateri.
- Sulit memverifikasi apakah jawaban chatbot benar-benar bersumber dari dokumen milik pengguna.
- Pengguna tidak selalu ingin dokumen pribadi dikirim ke server pihak ketiga.
- Membaca ulang puluhan PDF/PPT membutuhkan waktu dan sering mengulang materi yang sama.

3. Target Users & Jobs-to-be-Done

Primary persona: Mahasiswa teknik/informatika

Mengunggah PPT perkuliahan, modul PDF, dan DOCX tugas. Ingin bertanya dalam bahasa Indonesia, mendapatkan contoh, latihan, rangkuman, dan rujukan halaman saat offline.

Secondary persona: Peneliti, profesional, dan project manager

Mengelola paper, dokumen produk, notulen, SOP, laporan, dan spesifikasi. Membutuhkan tanya-jawab lintas dokumen dan pembandingan versi tanpa membocorkan konten ke cloud.

Jobs-to-be-done

1. “Ketika saya menambahkan modul, saya ingin materi tersebut tetap bisa dicari setelah laptop offline.”
2. “Ketika saya meminta penjelasan, saya ingin tahu halaman/slide mana yang mendukungnya.”
3. “Ketika saya belajar suatu topik, saya ingin AI menjelaskan dari nol dan membuat latihan.”
4. “Ketika dua dokumen berbeda, saya ingin AI menunjukkan perbedaannya, bukan mencampurnya diam-diam.”
5. “Ketika saya beralih semester atau proyek, saya ingin ruang pengetahuan yang terpisah.”

4. Product Principles

1. **Offline is a feature, not a fallback:** Chat, ingest, indexing, search, and export versi MVP harus bisa berjalan tanpa jaringan setelah setup awal selesai.
2. **Source-grounded by default:** Jawaban tentang dokumen harus disertai provenance yang bisa dibuka.
3. **Privacy and control:** Semua penyimpanan lokal secara default; tanpa telemetri atau upload otomatis.
4. **No imaginary memory:** Bedakan memori percakapan, fakta dari dokumen, dan inferensi model.
5. **Graceful degradation:** Aplikasi memberi peringatan bila RAM/VRAM tidak cukup, bukan crash atau mengklaim berhasil.
6. **Human-friendly:** Bahasa Indonesia dan Inggris, terminal UX intuitif, akses cepat ke sumber, format output ramah terminal.
7. **Modular:** Parsing, embedding, retrieval, dan model inference dapat diganti tanpa mengubah seluruh aplikasi.

5. Goals & Non-Goals

Goals (MVP)

- CLI bhap dapat dijalankan dari shell (Bash, Fish, Zsh, PowerShell); dapat dipasang setelah `git clone`.
- Impor PDF, DOCX, PPTX, MD, dan TXT via argumen file/folder serta stdin opsional.
- Metadata halaman, slide, bagian, judul, dan nama file dipertahankan sedapat mungkin.
- Model lokal menjawab pertanyaan dari koleksi dokumen secara offline.
- Sitasi file + halaman/slide/bagian di terminal, dengan perintah pembuka sumber jika aplikasi tersedia.
- Workspace dan folder untuk memisahkan pengetahuan.
- Search semantik plus keyword (hybrid retrieval).
- Ringkasan, mode tutor, dan quiz sederhana.
- Menghapus dokumen serta indeks turunannya.
- Status offline dan kesiapan model terlihat jelas lewat bhap `doctor` dan bhap `status`.
- Berjalan tanpa GUI dan dapat dipakai oleh orang lain dari repo publik yang terdokumentasi.

Non-goals (MVP)

- Fine-tuning LLM otomatis setiap upload.
- Membuat model foundation sendiri.
- Cloud sync, multi-user kolaborasi, web crawling otomatis.

- Pemahaman sempurna terhadap semua diagram, gambar, tabel rumit, dan tulisan tangan.
- Eksekusi shell/code/operasi filesystem secara otomatis oleh AI.
- Mengakses internet diam-diam untuk mengisi pengetahuan yang hilang.

6. Scope & Feature Priorities

ID	Feature	Priority	Release	Description
F01	Local Model Manager	P0	MVP	Pilih model LLM, model embedding, dan status siap-offline
F02	Document Ingestion	P0	MVP	CLI import path/glob/directory, batch parsing, status job
F03	Local Knowledge Index	P0	MVP	Normalisasi, chunking, embed-dings, metadata, penyim-panan lokal
F04	Grounded Chat	P0	MVP	Q&A dari dokumen dengan kontrol scope workspace
F05	Verifiable Citations	P0	MVP	Tautan nama file + hala-man/slide/section + snippet
F06	Workspaces	P0	MVP	Koleksi terpisah per mata kuliah atau proyek

ID	Feature	Priority	Release	Description
F07	Knowledge Search	P0	MVP	Hybrid keyword + vector search
F08	Source Preview	P0	MVP	Tampilkan kutipan + lokasi sumber di terminal; `source open` opsional
F09	Document Lifecycle	P0	MVP	Reindex, ganti versi, hapus dokumen dan embeddings
F10	Study Mode	P1	v1.1	Tutor adaptif, flashcards, quiz, latihan
F11	Cross-Document Synthesis	P1	v1.1	Bandingkan, gabungkan, deteksi perbedaan antar sumber
F12	Knowledge Graph	P2	v2	Visualisasi hubungan konsep dan dokumen
F13	Smart Notes	P1	v1.1	Catatan berpranala sumber, ekspor Markdown
F14	OCR Scanned PDFs	P1	v1.1	OCR lokal dengan status confidence

ID	Feature	Priority	Release	Description
F15	Multimodal Figure/Diagram	P2	v2	Ekstraksi atau pemahaman visual dengan model pendukung
F16	Folder Watcher	P2	v2	Reindex perubahan file dalam folder yang dipilih
F17	Optional Encrypted Backup	P1	v1.1	Backup dan restore offline, opsional enkripsi
F18	Optional Network Sync	P3	Future	Sinkronisasi eksplisit berbasis persetujuan
F19	CLI & Interactive TUI	P0	MVP	Subcommand bhap, chat interaktif, `--help`, noninteractive output
F20	Git Clone Onboarding	P0	MVP	README, prerequisites, setup, quickstart, troubleshooting
F21	Distribution & Versioning	P0	MVP	pyproject.toml, packaging, release tags, CI lint/test
F22	Headless Operation	P0	MVP	Support SSH/WSL/headless; zero desktop dependency

ID	Feature	Priority	Release	Description
F23	Offline Diagnostic	P0	MVP	Periksa runtime, model, embedding, parser, dan network-free tests
F24	Portable Knowledge Export	P1	v1.1	Backup/restore workspace dengan manifest kompatibilitas

7. Key User Flows

Flow A — First launch

1. Pengguna `git clone` repository dan mengikuti README, atau memasang package yang dirilis.
2. `bhap doctor` memeriksa OS, Python, runtime LLM, RAM/VRAM dan ruang penyimpanan; `bhap setup` menawarkan pilihan model dan ukuran unduhan.
3. Saat online, pengguna mengunduh atau mengimpor manual model dan aset parser/OCR yang diperlukan.
4. `bhap doctor --offline` melakukan **Offline Readiness Check** (model, tokenizer, parser, embedding engine, DB lokal).
5. Aplikasi menawarkan tes “Disconnect and verify” tanpa mengharuskan internet.
6. Pengguna membuat workspace pertama dengan `bhap workspace create kuliah`.

Flow B — Upload & learn

1. Pengguna memilih workspace “Basis Data”.
2. Jalankan `bhap add pbd1.pdf pbd2.pdf relational-model.pptx --workspace basis-data`.
3. Terminal menampilkan progres tiap file: queued → extracting → chunking → embedding → indexed; atau failed dengan error spesifik.
4. `bhap docs list` menampilkan statistik halaman/slide, hasil parsing, dan peringatan bagian yang tidak terbaca.

5. Pengguna dapat bertanya segera setelah dokumen berstatus indexed.

Flow C — Offline grounded chat

1. Wi-Fi dimatikan.
2. Pengguna bertanya “Apa beda ERD konseptual dan model relasional menurut materi yang aku upload?”
3. Sistem mencari konten dalam workspace lokal; rerank bila tersedia.
4. LLM lokal menjawab berdasarkan potongan dokumen yang terpilih.
5. Setiap pernyataan penting memiliki sitasi file + halaman/slide, atau ditandai sebagai pengetahuan umum/inferensi.
6. Klik sitasi membuka preview dan menyorot konteks yang mendukung.

Flow D — Belajar dan evaluasi

1. Pengguna memilih topik Dijkstra.
2. Pilih mode “Teach from zero”.
3. Sistem menyusun penjelasan bertahap, contoh, dan 5 pertanyaan latihan berdasarkan dokumen.
4. Setelah pengguna menjawab, AI memberikan umpan balik dan menunjukkan rujukan sumber.
5. Kemajuan belajar disimpan secara lokal dan dapat dihapus.

8. Functional Requirements

8.1 File import

- Mendukung multi-file, progress per file, pembatalan, retry, duplicate detection memakai hash konten.
- Tetapkan batas ukuran konfigurabel dan uji dokumen besar secara eksplisit.
- Simpan file asli secara lokal, atau mode referensi-ke-lokasi-asal dengan peringatan jika file dipindah.
- Untuk PPTX, simpan indeks slide, heading, bullet, table, dan speaker notes bila berhasil diekstrak dan diaktifkan.
- Untuk DOCX, simpan heading hierarchy, tabel, dan penanda section.
- Untuk PDF, simpan nomor halaman, urutan baca, struktur tabel, serta bounding box jika didukung parser.
- File `.ppt`/`.doc` lama merupakan tahap setelah MVP: konversi lokal diperlukan sebelum diproses.

8.2 Knowledge pipeline

- Parsing ke format dokumen terstruktur yang seragam.
- Chunking berdasarkan heading, halaman, slide, tabel, dan batas token; chunk overlap secukupnya.
- Embedding dibuat dan disimpan hanya melalui model embedding lokal.
- Setiap chunk menyimpan document_id, version_id, locator, text, hash, dan posisi sumber bila tersedia.
- Hindari embedding ulang untuk file tidak berubah.
- Hybrid retrieval: lexical/full-text + vector retrieval → fusion → optional local reranking.
- Batasi top-k, diversifikasi sumber, dan atur jumlah context tokens mengikuti kapasitas LLM.

8.3 Chat & answer grounding

- Mode **Source Only** (ketat): hanya jawab bila ada bukti dokumen; jika tidak, katakan "Tidak ditemukan dalam materi yang dipilih."
- Mode **Source + General Knowledge**: bedakan eksplisit informasi berbasis dokumen dan penjelasan umum.
- Mode **Brainstorm**: penalaran kreatif dengan label inferensi, bukan klaim sumber.
- Filter scope: seluruh workspace, folder, file tertentu, atau pilihan beberapa file.
- History percakapan tersimpan lokal, bisa dicari, dihapus, dan diekspor.
- Mencegah konten dokumen yang berisi instruksi berbahaya diperlakukan sebagai perintah sistem.

8.4 Citation integrity

- Format contoh: `BasisData.pdf — halaman 12` atau `Graph.pptx — slide 8`.
- Setiap citation mengacu ke chunk/referensi valid di database dan lokasi sumber.
- Jangan menghasilkan nomor halaman/slide sendiri dari teks generatif.
- Tampilkan kutipan pendek dari konteks sumber.
- Jika sumber bertentangan, tampilkan perbedaan dan asal masing-masing.
- Jika sumber tidak dapat di-preview, beri fallback ke teks ekstraksi dan jelaskan keterbatasan.

8.5 Study tools

- Generate ringkasan bertingkat (30 detik, 5 menit, lengkap).
- Membuat flashcards dengan rujukan.
- Generate soal pilihan ganda dan uraian dengan kunci, penjelasan, dan referensi.
- Mode Socratic Tutor: memberi petunjuk bertahap, bukan langsung jawaban.
- Export hasil belajar ke `.md` atau `.json`; PDF export dapat menyusul.

9. Innovative Features (Post-MVP)

9.1 Knowledge Constellation

Graf interaktif yang memperlihatkan hubungan dokumen → bab → topik → konsep. Klik node untuk melihat materi dan pertanyaan relevan. Visualisasi ini *optional* dan tidak memblokir fungsi utama pada hardware lemah.

9.2 Knowledge Gap Detector

Ketika user bertanya tentang konsep yang tidak ada di koleksi, tampilkan kekurangan yang terdeteksi dan sarankan jenis materi yang bisa diimpor. **Tidak mengarang materi yang belum dimiliki.**

9.3 Contradiction Radar

Menandai konflik definisi, angka, atau prosedur di dua dokumen dan meminta pengguna memilih sumber yang lebih otoritatif.

9.4 Concept Memory, not just Chat Memory

Simpan catatan terstruktur tentang topik yang telah dipelajari, kesulitan yang dinyatakan pengguna, dan link sumber. Hindari menyatakan model “sudah menguasai” sesuatu hanya karena dokumennya telah diindeks.

9.5 Exam Sprint

Pengguna memilih topik dan tingkat kesulitan, lalu sistem membuat sesi latihan yang memfokuskan materi yang sering salah. Tidak menggunakan internet.

9.6 Pack & Go

Membuat paket portable: file asli (opsional), database, embedding, notes, dan manifest versi; periksa kompatibilitas model dan enkripsi sebelum restore ke perangkat lain.

9.7 Evidence Map

Untuk pertanyaan kompleks, tampilkan daftar klaim jawaban dan sumber pendukungnya; bagian tanpa bukti diberi label “inferensi”.

10. UX/UI Specification

Design direction: Developer-first terminal ergonomics: fast, keyboard-native, no unnecessary splash animations. TUI menggunakan warna subtil, output dapat dibaca tanpa true-color, mendukung `NO_COLOR` dan non-TTY fallback. GUI desktop premium adalah layer sekunder yang tidak boleh menghambat CLI.

TUI Navigation: workspace selector, conversations, documents, status, sources; shortcut `?` untuk help, `/` command palette, dan `Ctrl+C` untuk cancel. GUI optional menggunakan sidebar Home/Workspaces/Library/Study/Search/Settings.

CLI/TUI views dan GUI opsional: 1. **Onboarding / Model Setup:** `bhap doctor`, `bhap setup`, `bhap status`. 2. **Home:** recent workspaces, recently indexed docs, continue learning, system status. 3. **Workspace:** chat, daftar file, filters, modes, source panel. 4. **Knowledge Library:** document cards/list, status, search, version history. 5. **Document Reader:** page/slide preview, highlight supporting passages. 6. **Study Studio:** tutor, cards, quiz, progress history. 7. **Settings:** model, inference settings, storage, backup, network permissions.

Terminal ergonomics: output streaming, spinner hanya di TTY, progress indexing, error actionable, exit codes, stdin/stdout piping, stdout untuk hasil dan stderr untuk progres, `--json` untuk automasi, `--no-color`, accessible rendering. GUI opsional dapat punya skeleton dan responsive panes.

Core states: `Offline — Ready`, `Offline — Setup Incomplete`, `Indexing`, `Low Memory`, `Source Not Found`, `Model Unavailable`, `Document Parsing Warning`. Never imply documents are searchable until indexing succeeds.

11. Technical Architecture

```
flowchart TD
    A[bhap CLI / Interactive TUI] --> B[Python Core Library / Orchestrator]
    X[Optional Desktop GUI / Local API] --> B
    B --> C[Ingestion Queue]
    C --> D[Parser - Docling]
    D --> E[Structured Documents + Provenance]
    E --> F[Chunking]
    F --> G[Local Embedding Model]
    G --> H[(Vector Index - LanceDB)]
    E --> I[(Metadata and Chat - SQLite)]
    E --> J[(Original Local Files)]
    B --> L[Hybrid Retrieval]
    H --> L
    I --> L
    L --> M[Context + Citation Assembler]
    M --> N[Local LLM - Ollama / llama.cpp]
    N --> O[Grounded Answer + Verified Citations]
    O --> A
    O --> X
```

Suggested tech stack

Layer	Choice	Rationale
Primary CLI	Python + Typer + Rich	Fast subcommands, help, interactive terminal output
Optional TUI	Textual (after core CLI is stable)	Keyboard-focused multi-pane terminal experience
Optional GUI	Tauri 2 + React + TypeScript + Tailwind	Layer desktop setelah CLI MVP, UI fleksibel
Core engine	Python package, modular services	Engine dapat dipanggil CLI tanpa service wajib
Optional local API	FastAPI	Hanya untuk integrasi GUI / opt-in localhost API
PDF/DOCX/PPTX extraction	Docling	Parsing berbagai dokumen ke struktur seragam

Layer	Choice	Rationale
LLM runtime	Ollama for MVP; llama.cpp as optional adapter	Pengelolaan model lokal dan inference
Generation model	Pilihan GGUF / model yang didukung runtime, misalnya kelas 3B–8B	Hardware-aware; benchmark sebelum memilih default
Embedding	Local multilingual embedding model	Pencarian Indonesia/Inggris
Vector storage	LanceDB embedded	Indeks lokal di disk, tanpa server DB wajib
Metadata, session, FTS	SQLite	Sederhana, portable, mendukung full-text indexing
Background jobs	Local persistent worker queue	Resume/cancel/retry indexing setelah restart
Logging	Structured local logs	Debug tanpa telemetry eksternal
Packaging	`pyproject.toml` console scripts, `uv`/`pipx`/`pip`	Clone/install lalu perintah bhap tersedia; wheel + tagged releases
CI	GitHub Actions (or equivalent)	Test CLI, OS matrix, packaging, lint; CI online tidak dibutuhkan saat penggunaan

Catatan teknis: Pilihan library dan model harus dipin pada versi yang diuji saat implementasi; model generatif dan embedding bukan aset yang sama. Model yang dibutuhkan untuk OCR/reranking juga harus tersedia sebelum offline. Tauri + sidecar Python (opsional) membutuhkan packaging dan pengujian proses rapi. CLI harus tetap bisa beroperasi tanpa Tauri, server FastAPI, atau layanan cloud.

Data directory (conceptual)

```
~/.local/share/bhap/   # Linux; gunakan platformdirs untuk lokasi per OS
├── config/
├── models/              # atau referensi ke model store terkelola
├── workspaces/
```

```
│   └── <workspace-id>/
│       ├── originals/
│       ├── parsed/
│       └── exports/
├── db/
│   ├── bhap.sqlite
│   └── vectors/
├── cache/
├── backups/
└── logs/
```

Core database entities

- workspaces(id, name, description, created_at)
- documents(id, workspace_id, title, original_path, sha256, status, created_at)
- document_versions(id, document_id, sha256, parser_version, indexed_at)
- chunks(id, document_version_id, text, page_no, slide_no, section_path, bbox, token_count)
- embeddings(chunk_id, embedding_model_id, vector_ref, created_at)
- conversations(id, workspace_id, mode, created_at)
- messages(id, conversation_id, role, text, created_at)
- message_citations(message_id, chunk_id, locator, evidence_excerpt)
- study_items(id, workspace_id, type, prompt, solution, source_refs)
- jobs(id, type, target_id, status, progress, error, created_at)

12. Critical Architecture Decisions

RAG vs fine-tuning

Default = RAG. Memasukkan file baru memperbarui pengetahuan yang dapat diambil dari local index, **bukan** mengubah bobot model. Fine-tuning/LoRA dapat dieksplorasi untuk gaya atau tugas spesifik di masa depan, tetapi bukan syarat agar AI “mengingat” dokumen.

Local-first network behavior

- Startup, chat, ingestion, embedding, search, viewer, dan export tidak boleh membutuhkan internet.

- Semua permintaan jaringan dimatikan secara default selama penggunaan inti.
- Download/update model hanya lewat interaksi eksplisit pengguna.
- Telemetri dan auto-upload dinonaktifkan.
- Audit seluruh library dan dependency yang mungkin melakukan network call.

Handling images and diagrams

- MVP membaca teks/struktur yang dapat diekstrak, bukan menjamin memahami gambar kompleks.
- Untuk gambar penuh atau diagram, beri badge “Visual content may not have been interpreted”.
- Versi berikutnya menggunakan local vision-capable model dan rendering pipeline, setelah pengujian hardware dan akurasi.

Privacy and security

- File tetap di storage milik user.
- Sanitasi nama file, tipe file, dan path; lindungi dari path traversal dan dokumen berbahaya.
- Parsing dijalankan dalam worker terisolasi dengan resource limits.
- Tool execution (shell, Python, filesystem writes) **nonaktif** secara default; jika kelak ditambah, gunakan izin per aksi.
- Anggap seluruh teks di dokumen sebagai *untrusted content* yang tidak boleh mengganti system instructions.
- Hapus semua turunan dokumen (parsed, chunks, vectors, cache) saat hard delete.
- Opsional enkripsi at-rest, dengan perhatian pada manajemen kunci dan backup.

13. Hardware & Performance Strategy

Ini **perkiraan target awal**, bukan garansi; performa akan bervariasi berdasarkan quantization, context length, ukuran dokumen, engine, dan model tertentu.

Profile	Hardware indication	Suggested experience
Lite	8 GB RAM, CPU inference	Model kecil quantized, context ringkas, sequential jobs
Standard	16 GB RAM, iGPU/CPU	Model kelas 3B–8B quantized sesuai memory, indexing background
Power	32 GB+ RAM / GPU dengan VRAM cukup	Model lebih besar, reranking, context lebih luas

Engineering objectives, to be validated: - Aplikasi tidak melakukan network request saat offline test. - Setelah diindeks, jawaban dari 1.000 halaman dokumen harus dapat diambil tanpa reload seluruh dokumen ke RAM. - UI tetap responsif selama indexing. - Baseline first-token latency dan token/s diukur pada laptop target; jangan menjanjikan angka universal. - Pilihan “Low Resource Mode”: batch kecil, model lebih kecil, membatasi concurrency, reranker opsional, lazy loading.

14. Non-Functional Requirements

Category	Requirement
Availability	Core features tetap operasional pada tes airplane mode
Reliability	Queue restart-safe; indexing atomic, status tidak false-positive
Retrieval correctness	Source links valid dan locator menunjuk ke bagian yang ditampilkan
Latency	Benchmark dataset/hardware standar; target akhir berdasarkan hasil pengujian
Security	Local by default; network egress explicitly permitted only
Accessibility	Keyboard navigation, readable contrast, reduced motion
Localization	Bahasa Indonesia dan Inggris

Category	Requirement
Maintainability	Adapter per runtime/parser/vector store; automated test suite
Observability	Logs tersimpan lokal dan bisa diekspor dengan redaction
Portability	Backup/restore dengan manifest format, versi indeks, model dependency

15. Success Metrics & Acceptance Criteria

Product metrics

- **Offline success rate:** 100% dari tes alur inti pada lingkungan jaringan diblokir, setelah setup selesai.
- **Citation validity:** ≥ 98% sitasi pada dataset uji menunjuk dokumen dan halaman/slide yang benar (target).
- **Grounded answer quality:** ≥ 85% pertanyaan yang memiliki bukti menghasilkan jawaban tepat dan didukung bukti menurut review manusia (target awal).
- **Abstention:** ≥ 90% pertanyaan yang tidak memiliki jawaban di sumber diberi penolakan epistemik yang benar dalam Source Only mode (target awal).
- **Document pipeline:** ≥ 95% dokumen valid dalam dataset uji teks-dominan terindeks tanpa kegagalan fatal (target awal; scan/diagram diuji terpisah).
- **Deletion correctness:** 100% artefak turunan yang diketahui untuk file terhapus tidak muncul lagi di search.

MVP definition of done

1. Pengguna bisa mengunduh/impor model saat online, kemudian mematikan Wi-Fi dan menjalankan aplikasi tanpa error jaringan.
2. Impor PDF, DOCX, PPTX, MD/TXT menghasilkan indeks yang persisten setelah restart.
3. Bertanya dari dua file sekaligus menghasilkan respons relevan dengan sumber akurat.
4. Klik citation membuka lokasi halaman/slide/section yang benar bila parser mengekstraknya.
5. Pertanyaan yang tidak ada jawabannya ditolak dalam Source Only.
6. Menghapus file menghapus chunk dan embedding turunannya dari workspace.

7. Indexing file identik tidak membuat duplikat tanpa izin.
8. Workspaces mengisolasi retrieval agar materi tidak tercampur tanpa pilihan pengguna.
9. Aplikasi memberikan status jelas untuk dokumen scan/diagram yang belum dibaca sempurna.
10. App tetap usable pada profil hardware minimum yang telah diuji.

16. Test Plan

Offline tests

- Firewall block seluruh egress untuk proses UI, sidecar, model runtime, parser; jalankan upload, chat, citation preview, quiz, export, restart.
- Reboot perangkat tanpa internet dan validasi semua aset model tetap tersedia.

Retrieval tests

- Pertanyaan dengan jawaban langsung, paraphrase, multi-hop lintas dokumen, informasi bertentangan, jawaban tidak tersedia.
- Dokumen dalam Bahasa Indonesia, Inggris, dan campuran.
- Source locator pada PDF multipage, DOCX dengan heading, PPTX dengan slide.

Ingestion tests

- File rusak, file kosong, ukuran besar, PDF scan, tabel, diagram, bahasa campuran, duplikat, pergantian versi.
- Cancel indexing, restart saat progress 50%, low disk, low RAM.

Security tests

- Prompt injection dalam dokumen, nama file tidak aman, file extension spoofing, symlink/path traversal, zip bombs, malicious embedded content.
- Pastikan sumber dokumen tidak dapat memicu perintah sistem atau jaringan.

17. Delivery Roadmap

Phase 0 — Feasibility Spike

- Uji 2–3 model lokal pada perangkat target; profil RAM, VRAM, tokens/s.

- Uji Docling pada contoh PDF/DOCX/PPTX sebenarnya termasuk slide berdiagram.
- Pilih model embedding multilingual dengan benchmark retrieval kecil.
- Buat prototype CLI: parse → embed → retrieve → generate + citation. **Exit gate:** semua proses dapat berjalan tanpa internet setelah model terpasang.

Phase 1 — MVP Core

- CLI package, commands, workspace, import file, local RAG, chat, citations, source excerpts, lifecycle.
- README `git clone` quickstart, `pyproject.toml`, persisted metadata and vector store, CI, offline readiness check. **Exit gate:** lulus 10 MVP definition-of-done.

Phase 2 — Learning Intelligence

- Study Mode, flashcards, source-linked notes, OCR, reranking, import/export backup.
- Perf tuning CPU/iGPU, low-resource mode.

Phase 3 — Advanced Knowledge

- Knowledge Constellation, Contradiction Radar, Evidence Map, local vision processing, folder watcher.

Phase 4 — Optional Ecosystem

- Optional TUI enhanced experience and desktop GUI; both use CLI core engine.
- Opt-in LAN sync, explicit remote model mode, plugins/tools with strict user permissions.
- Tetap mempertahankan pengalaman offline sebagai mode utama.

18. Risks & Mitigations

Risk	Impact	Mitigation
LLM halusinasi	Salah paham terhadap materi	Source Only, citations, abstention, human review

Risk	Impact	Mitigation
Diagram/gambar tidak terbaca	Materi teknis tidak lengkap	Parsing warnings, local vision roadmap
Lambat pada RAM rendah	UX buruk	Quantized small models, low-resource mode, profiling
PDF layout salah terbaca	Retrieval misleading	Structured parsing, source preview, extraction QA
Citation palsu	Hilang trust	Generate citations from verified retrieval IDs, not raw LLM output
Prompt injection lewat dokumen	Privacy/security risk	Instruction/data isolation, no auto tool execution
Migrasi embedding model	Index tidak kompatibel	Store model ID/dimensions; versioned rebuild
File besar dan cache membengkak	Disk penuh	Storage quota, cleanup, dedupe, disk warning
Backup berisi data sensitif	Privacy leak	Encryption option, explicit destination, no auto sync
Packaging Python/LLM runtime	Installer rumit	Platform CI, dependency manifest, first-run checks

19. Open Questions / Product Decisions

1. Rilis pertama: Linux sebagai development target, CI Windows/macOS bila kompatibilitas tercapai; jujur tentang support matrix.
2. Apakah file original disalin ke library Bhap atau hanya direferensikan?
3. Model LLM dan embedding mana paling sesuai setelah benchmark di hardware target?
4. Apakah DOCX notes/footnotes dan PPTX speaker notes termasuk sumber secara default?
5. Kapan enhanced TUI dan GUI diluncurkan tanpa memperlambat core CLI?
6. Apakah user memerlukan enkripsi dan passphrase sejak MVP?

7. Dataset evaluasi dokumen teknis Indonesia apa yang digunakan sebagai acceptance benchmark?

20. Recommended Development Order

Do not start with fancy UI or autonomous agents. Mulailah dari retrieval yang dapat diuji dan sitasi yang akurat:

1. `offline-rag-core`: parse 3 format, chunk, local embed, hybrid search, answer + verified source ID.
2. `bhap-cli`: `pyproject.toml`, command tree, terminal chat, workspaces, docs, citations, packaging, README clone-and-run.
3. `reliability`: jobs, caching, deletion, migration, backup, resource guardrails, cross-platform integration tests.
4. `learning-suite`: teaching, quiz, notes, review progress.
5. `optional-interfaces`: enhanced TUI and desktop GUI using the same core library.
6. `advanced-intelligence`: graph, OCR/vision, contradictions, optional tool integrations.

21. Example End-to-End Scenario

Pengguna menjalankan `bhap add Graph.pdf Dijkstra.pptx Latihan.docx -w kuliah` untuk mengimpor `Graph.pdf` (materi konsep graf), `Dijkstra.pptx` (algoritma), dan `Latihan.docx` (soal). Bhap memproses ketiganya di laptop serta membuat indeks lokal. Setelah mematikan Wi-Fi, pengguna bertanya: **“Ajari saya Dijkstra dari nol berdasarkan materi ini, jelaskan tahap demi tahap, lalu buat 3 soal latihan.”** Bhap mengambil bagian relevan dari beberapa dokumen, menjelaskan syarat bobot non-negatif dan langkah algoritma, memberi contoh penyelesaian, membuat soal baru, dan menghubungkan pembahasannya ke halaman/slide yang mendukung. Bila latihan meminta hal di luar dokumen, Bhap menandainya sebagai contoh buatan AI, bukan kutipan materi.

---

22. Terminal-first CLI Product Contract (P0)

Tujuan: `bhap` adalah satu executable command yang tetap dapat dipakai dalam terminal biasa, terminal IDE, SSH, dan script. **Tidak perlu browser atau server berjalan untuk chat**; runtime model lokal dapat berupa proses Ollama di `localhost` atau adapter `llama.cpp` yang tersedia lokal. Koneksi localhost bukan akses internet.

22.1 Quickstart untuk kontributor/pengguna

```
# Prasyarat: Git, Python yang kompatibel, Python package installer; runtime LLM
# URL hanya placeholder sampai repo nyata tersedia
# git clone https://github.com/<owner>/bhap.git
# cd bhap
# python -m venv .venv
# source .venv/bin/activate   # Windows PowerShell: .venv\Scripts\Activate.ps1
# python -m pip install -e .
# bhap doctor
# bhap setup               # boleh download model pada setup awal (dengan consen
# bhap workspace create kuliah
# bhap add ./materi/ --workspace kuliah --recursive
# bhap                     # directly launch interactive assistant
# bhap chat --workspace kuliah   # optional backward-compatible alias
# bhap ask "Apa itu normalisasi database?" --workspace kuliah --sources
# bhap doctor --offline
```

Catatan: Ini adalah *target command interface* untuk diimplementasikan, bukan klaim bahwa repo atau command tersebut sudah tersedia. `bhap setup` harus memberikan instruksi saat runtime Ollama belum terinstal; tidak boleh melakukan perubahan sistem diam-diam. Alternatif instalasi package versi release: `pipx install bhap-ai` atau `uv tool install bhap-ai` **hanya jika nama package sudah benar-benar dipublikasikan dan tersedia**.

22.2 CLI command surface

Command	Fungsi	Output
`bhap`	**Directly open interactive assistant** (default command)	Interactive TUI/REPL
`bhap --help`	Help dan contoh	Text
`bhap doctor [--offline]`	Diagnostik hardware/dependencies/model status	Checklist + exit status
`bhap setup`	Wizard konfigurasi lokal	Konfirmasi setiap download
`bhap status [--json]`	Status engine, storage, model, workspace	Human/JSON
`bhap workspace create/list/use/delete`	Manajemen workspace	Text/JSON

Command	Fungsi	Output
`bhap add <paths...> -w <name> [--recursive]`	Import PDF/DOCX/PPTX/MD/TXT	Progress + indexed IDs
`bhap docs list/show/remove/reindex`	Kelola sumber dokumen	Metadata + source locators
`bhap chat [-w <name>]`	Interactive REPL chat	Streaming answer + citations
`bhap ask <prompt> [-w <name>] [--json]`	Single-shot Q&A, cocok scripting	Text/JSON
`bhap search <query> [-w <name>]`	Pencarian sumber	Results + page/slide
`bhap summarize <doc-id>`	Ringkasan berbasis sumber	Markdown
`bhap study quiz <topic>`	Latihan topik	Interactive/text
`bhap model list/use`	Pilih LLM lokal	Model metadata
`bhap backup create/restore`	Portable knowledge pack	Manifest + file
`bhap config show/set`	Pengaturan lokal	Text/JSON

22.3 Terminal behavior

- `bhap ask` tanpa TTY **tidak** membuka prompt interaktif; mendukung argumen prompt atau `--stdin` untuk piping.
- Hasil jawaban ke stdout; progres/warning ke stderr. `--json` menghasilkan JSON valid dan stabil tanpa spinner atau ANSI.
- Chat interaktif mendukung `/help`, `/sources`, `/model`, `/workspace`, `/clear` (clear context sesi bukan hapus DB), `/exit`.
- Help serta error harus menunjukkan perintah perbaikan yang jelas, contoh `bhap setup` ketika model belum terpasang.
- Exit status: `0` sukses, kode nonzero konsisten untuk invalid args, missing model, parsing failure, corrupt DB.
- Opt-in network operations (`bhap setup --download`, `bhap model pull`) dipisahkan dari pemrosesan dokumen dan chat.
- Lokasi data mengikuti OS; `BHAP_HOME` dapat mengubah root data untuk pengujian, portabilitas, atau disk eksternal.

23. Open-source & Git Clone Distribution (P0)

23.1 Repository proposal

```
bhap/
├── README.md
├── LICENSE
├── CONTRIBUTING.md
├── SECURITY.md
├── CHANGELOG.md
├── pyproject.toml
├── uv.lock                      # jika menggunakan uv
├── .gitignore
├── .github/workflows/ci.yml
├── src/bhap/
│   ├── __init__.py
│   ├── cli.py                   # entrypoint: bhap
│   ├── config.py
│   ├── core/
│   │   ├── ingest.py
│   │   ├── chunking.py
│   │   ├── retrieval.py
│   │   ├── generation.py
│   │   └── citations.py
│   ├── adapters/
│   │   ├── llm_ollama.py
│   │   ├── llm_llamacpp.py
│   │   └── parser_docling.py
│   ├── storage/
│   │   ├── sqlite.py
│   │   └── vectors.py
│   ├── tui/                     # optional phase
│   └── commands/
├── tests/
│   ├── unit/
│   ├── integration/
│   └── offline/
├── docs/
│   ├── installation.md
│   ├── offline-setup.md
│   ├── cli-reference.md
│   ├── model-support.md
│   └── troubleshooting.md
└── examples/
```

Git hygiene: `.gitignore` harus mengecualikan model weights, file pengguna, embeddings, chat database, caches, .env/secrets, vir-

tualenv, dan hasil build. Jangan pernah commit materi pengguna ke Git. Model weights didistribusikan melalui runtime/unduhan terpisah; lisensi model dan aset parser harus diperiksa sebelum redistribusi.

23.2 Onboarding & release strategy

- README memiliki install untuk Linux (termasuk Arch/CachyOS), Windows, macOS, plus `bhap --help` dan satu skenario offline lengkap.
- CI menjalankan `python -m pip install -e .`, unit tests, CLI smoke test, lint/type checks pada OS yang didukung; integration test berbasis LLM lokal dipisah agar CI tidak selalu butuh model besar.
- Rilis ditandai semantic versioning, changelog, schema migration, dan pengujian upgrade dari versi sebelumnya.
- `pipx`/`uv tool` dan `git clone` mendistribusikan source+dependencies Python; model inferensi tetap prasyarat terpisah yang diverifikasi.
- GUI tidak wajib. Artefak biner standalone bisa ditambah kemudian; tidak boleh mengklaim *zero dependencies* sebelum benar-benar dibundel dan diuji.
- Lisensi proyek **belum diputuskan**: pilih MIT/Apache-2.0 sesuai tujuan; daftar third-party licenses dan attribution.

23.3 Security for public repositories

- Default bind local API (bila diaktifkan) ke `127.0.0.1`, bukan `0.0.0.0`; tidak expose ke LAN secara default.
- Dependency pinning, checksums untuk artefak model, audit dependency, dan signed releases bila memungkinkan.
- Parsing file tidak tepercaya dengan limit memori/durasi/ukuran dan penanganan zip bombs pada DOCX/PPTX.
- Tidak menjalankan macro, skrip tertanam, perintah shell, atau instruksi yang ditemukan di dokumen.
- README memperingatkan bahwa file berisi PII tetap tersimpan di disk; menawarkan enkripsi backup dan penghapusan data.

24. Terminal MVP Acceptance Tests

1. Fresh clone pada Linux dengan prerequisites yang terdokumentasi → `pip install -e .` → `bhap --help` bekerja.
2. `bhap doctor` mendeteksi missing Ollama/model/embedding dan memberikan tindakan perbaikan yang benar.
3. Setelah setup lengkap, matikan seluruh akses internet (bukan hanya sembunyikan Wi-Fi icon); `bhap add`, `bhap search`, `bhap`

ask, dan bhap chat tetap berhasil.
4. Restart terminal dan mesin: workspace, chat, file index, serta model selection tidak hilang.
5. Pertanyaan tentang PDF/PPTX/DOCX menampilkan sitasi ID dan lokasi sumber yang terverifikasi.
6. Test pertanyaan di luar isi materi dalam mode source-only menghasilkan abstention, bukan sitasi buatan.
7. bhap ask ... --json sukses diparse oleh tool eksternal dan tidak mengandung escape sequence spinner.
8. BHAP_HOME menunjuk lokasi terisolasi; dua instalasi tidak saling mencampur pengetahuan.
9. Penghapusan file workspace juga menghapus indeks turunan sesuai pilihan retention policy.
10. Clone dari akun/perangkat lain tidak membawa database pribadi, dokumen, atau model milik pengembang.

25. Updated Product Priorities

- **MVP:** bhap interactive-by-default, in-session cd/file paths, terminal CLI, reproducible setup, document ingestion, local RAG, reliable citations, workspace, diagnostics, truly offline operation, open-source documentation.
- **v1.1:** smarter study tools, backups, scanned PDF OCR, richer interactive terminal UI.
- **v2:** optional desktop GUI, visual knowledge graph, multimodal figures, encrypted portability and optional advanced integrations.
- **Guiding constraint:** jangan mengorbankan core CLI demi visual; semua fitur GUI harus memanggil engine yang sama.

26. Interactive-by-Default Experience: bhap (P0, v1.2)

26.1 One-command entry

Pengguna membuka terminal di folder mana pun dan menjalankan **bhap tanpa subcommand**. Bila berada di interactive TTY, program langsung masuk ke sesi asisten AI seperti Codex/Claude Code: input multi-turn, streaming response, header workspace, current working directory (cwd), model lokal, offline/ready status, dan jumlah dokumen aktif. Tidak mengharuskan bhap chat, memilih workspace manual setiap sesi, atau membuka web UI.

```
$ cd ~/Kuliah/Semester-3
$ bhap
```

```
  Bhap  ·  Offline AI
  ~/Kuliah/Semester-3    Workspace: semester-3
  Model: local-llm       Knowledge: 24 documents     ● Offline ready

bhap ❯ Jelaskan ERD berdasarkan materi yang saya punya
...
  Sources: pbd2.pdf p.11; basis-data.pptx slide 7

bhap ❯ cd ../Semester-4
✓ Working directory: ~/Kuliah/Semester-4

bhap ❯ ./jaringan/TugasBesar.pdf
✓ Imported TugasBesar.pdf · 24 pages · indexed locally

bhap ❯ Sekarang jelaskan spesifikasi tugasnya
...

bhap ❯ /exit
```

Contoh di atas adalah **desain interaksi target, bukan output aplikasi yang sudah berjalan**.

26.2 Working directory & context

- Start-up bhap menetapkan cwd dari lokasi shell saat dipanggil. `cd <path>`, `cd ..`, `cd ~` serta `pwd` bekerja **di dalam Bhap** pada virtual session cwd. Path relatif selalu ditafsirkan terhadap cwd ini; tidak mengubah cwd shell induk saat Bhap ditutup.
- bhap saat pertama berjalan dapat menggunakan workspace default personal (dibuat otomatis setelah setup) atau mengaitkan workspace proyek dengan folder aktif melalui `.bhap/config.toml`. **`cd` tidak otomatis memindah workspace** kecuali pengaturan `workspace.auto_switch=true`; tampilkan workspace aktif secara eksplisit.
- Current folder adalah **konteks navigasi**, bukan izin membaca/indeks seluruh isi folder secara otomatis. `cd` tidak memindai, membaca, atau mengirim file; file hanya diindeks melalui perintah eksplisit atau mode project-indexing yang diaktifkan pengguna.
- `ls`, `pwd`, `cd`, `clear` didukung sebagai navigasi lokal tanpa shell arbitrary execution. Untuk menjalankan shell command, gunakan mekanisme opt-in terpisah (misalnya `!<command>` dengan guardrail dan konfirmasi), **bukan** mengeksekusi setiap input sebagai shell.

26.3 File path sebagai input langsung (tanpa `bhap add`)

- Mengetik **path saja** di prompt mengimpor file tersebut ke knowledge base yang aktif, menampilkan progres, dan membuatnya tersedia untuk chat berikutnya. Contoh `./materi.pdf`, `../slide/week2.pptx`, `~/Documents/catatan.docx`, `/home/user/Kuliah/Graph.pdf`, dan path Windows `C:\Users\user\Documents\materi.pd`
- Path direktori seperti `./materi/` menampilkan ringkasan jumlah file terdukung dan **meminta persetujuan sebelum impor rekursif**, termasuk opsi exclude; tidak otomatis mengindeks seluruh home/repo tanpa kontrol.
- Sintaks eksplisit `/add <path...>` dan `/add --recursive <directory>` juga disediakan untuk batch dan untuk menghindari ambiguitas. Path ber-spasi dapat diapit tanda kutip: `/add "./Materi Basis Data/ERD final.pdf"`.
- Jika pengguna mengetik path absolut Unix `/home/user/file.pdf`, parser **mengenali path sebagai path, bukan slash command**. Slash commands hanya nama persis yang terdaftar (`/help`, `/add`, `/model`, `/workspace`, `/sources`, `/status`, `/exit`, dll.). Path nonexistent ditangani dengan pesan kesalahan dan saran, bukan diteruskan ke model.
- Input path yang menyertai pertanyaan: `Jelaskan isi @./materi/graph.pdf` atau `@./materi/graph.pdf rangkum bab 2`. Marker `@` memasukkan file ke konteks dan menawarkan impor/persistensi dengan status yang jelas. Ini **opsional setelah MVP**; fokus MVP adalah raw path dan `/add`.
- File yang sudah diindeks dikenali dengan fingerprint konten/hash; impor ulang identik tidak menghasilkan duplikasi, perubahan file memicu reindex dengan izin. PDF scan menjalani OCR lokal bila sudah terinstal.

26.4 Prompt routing priority

Pada setiap input di dalam TUI, router mengurutkan prioritas:

1. Exact registered slash command (`/help`, `/add`, `/exit`, dan lain-lain).
2. Built-in navigation (`cd`, `pwd`, `ls`, `clear`) dengan token parser yang menangani kutip/escape.
3. Existing filesystem path atau path-looking input (absolute, relative `.//..//~/`, drive-letter, path ber-extension yang dikenal), dengan validasi path, ekstensi, izin akses, dan limit.
4. Explicit file references `@<path>` (jika fitur diaktifkan).
5. Natural-language chat untuk input selain di atas.

Jika `cd` gagal, pertahankan cwd sebelumnya. Jika string ambigu antara path dan pertanyaan, jangan impor diam-diam; tampilkan pili-

han. Jangan memaksa model menebak sistem file atau mengklaim file dibaca sebelum indexing selesai.

26.5 Hotkeys & TUI ergonomics

- `Enter`: submit; `Shift+Enter` atau `Alt+Enter`: multiline tergantung terminal; `Ctrl+C` pertama membatalkan streaming, tidak langsung keluar; `Ctrl+D` atau `/exit` menutup sesi.
- ↑ dan ↓: input history; Tab: completion untuk path dan slash commands; / menampilkan command picker; `Ctrl+L`: clear display; persistent chat history opt-in dan tersimpan lokal.
- Header menampilkan cwd, workspace, model, indexing progress, dan status benar-benar offline. Bila model belum siap, tampilkan `bhap doctor`/`bhap setup` alih-alih crash.
- MVP tetap mendukung REPL plain terminal (SSH/low-color/non-TTY handling); enhanced panels dapat memakai Textual/Rich tetapi tidak wajib untuk core.

26.6 Command contract: interaktif vs script

User input	Expected behavior
bhap (from shell)	Open interactive session immediately
`bhap -w basis-data`	Open session on selected workspace
`bhap ask "..." --json`	Noninteractive one-shot result for automation
`cd ~/Kuliah` (inside Bhap)	Change session cwd only
`/home/user/Kuliah/pbd1.pdf`	Import one file, do not execute shell
`./slides`	Directory preview and confirm recursive import
`/add ./pbd1.pdf ./pbd2.pdf`	Explicit batch import
`/sources`	Display documents cited in last response
`/workspace use kuliah`	Switch active knowledge workspace
`/exit`	Quit and restore external shell unchanged

26.7 User acceptance tests

1. Install package, run bhap with no arguments and observe interactive UI in under a reasonable measured startup budget on sup-

ported machine, provided model is available.
2. Navigate directories via `cd`; `pwd` reflects in-session cwd; shell cwd remains unchanged after exit.
3. Input Unix absolute path `/home/.../doc.pdf` is imported rather than parsed as slash command.
4. Import both relative path and quoted path containing spaces; show progress and allow question after index ready.
5. Import folder must preview scope and ask approval before recursive scan; symlinks, file size limits, and ignored directories are handled safely.
6. `bhap` runs and answers offline after local model/dependencies were prepared; no network calls during ingestion/inference.
7. `bhap ask ... --json` remains noninteractive and deterministic for callers.
8. Input `/exit` quits cleanly and `Ctrl+C` cancels generation without corrupting chat or index.

Design principle: Bhap feels like an AI assistant native to the terminal, not a collection of commands the user must memorize. The default flow is **`bhap` → navigate with `cd` → paste a file path → ask questions**.

Reference Documentation

- Docling supported formats: https://docling-project.github.io/docling/usage/supported_forma
- Docling project overview: https://docling.ai/
- Ollama embeddings API: https://github.com/ollama/ollama/blob/main/docs/api.md
- LanceDB embedded database: https://lance.org/quickstart/lancedb/
- llama.cpp inference overview: https://huggingface.co/docs/inference-endpoints/engines/llama_cpp

PRD note: Library/model availability and exact platform support should be rechecked when implementation begins. Quality thresholds are proposed acceptance targets, not measured achievements.